Rapport de Recherche Stratégique sur l'Architecture Multimodale et les Plateformes d'Intelligence Artificielle pour JadaRiseLabs en 2025-2026

Le paysage technologique de l'intelligence artificielle traverse une ère de mutation fondamentale où l'accès à la puissance de calcul et aux modèles de pointe n'est plus l'apanage exclusif des géants de la Silicon Valley. L'émergence d'acteurs disruptifs, particulièrement en Chine et en Russie, a déclenché une guerre des prix et une libéralisation des accès gratuits sans précédent, redéfinissant les règles économiques pour les startups en phase d'amorçage.[1] Pour une entité comme JadaRiseLabs, qui ambitionne de devenir un laboratoire d'IA complet pour l'Afrique de l'Ouest avec un budget initial nul, cette conjoncture offre une fenêtre d'opportunité unique. Il ne s'agit plus seulement de consommer des services tiers, mais d'orchestrer intelligemment une mosaïque de plateformes offrant les meilleurs rapports qualité-prix, souvent par le biais de modèles open-source ou de paliers gratuits extrêmement généreux.[1]

Évolution du Paradigme Économique de l'IA : La Fin du Monopole Occidental

L'époque où l'accès à une IA de niveau GPT-4 coûtait des milliers de dollars par mois est révolue. En 2025, le laboratoire DeepSeek a prouvé qu'il était possible d'atteindre des performances de pointe avec un budget d'entraînement de seulement 5,6 millions de dollars, soit 100 fois moins que les approches traditionnelles d'OpenAI.[1] Cette efficacité se traduit par des APIs dont les coûts sont de 1/53ème inférieurs à ceux de modèles comme Claude 3.5 Sonnet, provoquant une guerre des prix systémique dans toute l'industrie.[1] Ce changement de paradigme est le moteur principal de la stratégie recommandée pour JadaRiseLabs : utiliser la puissance gratuite des leaders actuels pour générer de la valeur, attirer une base d'utilisateurs critique et financer ultérieurement des infrastructures plus performantes.[1]

La domination technologique s'est déplacée vers l'Est. En 2026, quatre des cinq modèles les plus sollicités mondialement sur des plateformes comme OpenRouter sont d'origine chinoise : MiniMax M2.5, Moonshot AI Kimi K2.5, Zhipu AI GLM-5 et DeepSeek V3.2.[2] Ces modèles ne se contentent pas de rivaliser en termes de performance ; ils redéfinissent l'efficacité architecturale par l'usage massif des systèmes Mixture-of-Experts (MoE) qui permettent de réduire la consommation de mémoire de 60 % tout en multipliant le débit par 19.[2] Pour JadaRiseLabs, l'exploitation de ces modèles est la clé pour offrir une qualité premium sans investissement lourd.[1]

Modules de Raisonnement et Traitement de Texte : Le

Cœur du Laboratoire

Le module de chat et d'assistance textuelle est le pilier central du laboratoire JadaRiseLabs. La priorité absolue est donnée à la vitesse et à la capacité de raisonnement complexe. Groq se positionne comme le sprinter indispensable pour les interactions en temps réel, offrant des vitesses de génération dépassant 300 tokens par seconde sur le modèle Llama 3.3 70B.[1] Cette réactivité est essentielle pour garantir une expérience utilisateur fluide, particulièrement sur les réseaux mobiles 3G/4G souvent instables en Afrique de l'Ouest.[3]
Pour les tâches nécessitant un raisonnement approfondi (Chain-of-Thought), DeepSeek-R1 est le modèle de référence. Il égale les performances d'OpenAI o1 sur les bancs d'essai mathématiques et de codage tout en étant accessible gratuitement via divers canaux ou à des tarifs dérisoires en API.[1] Une stratégie "cachée" pour maximiser la gratuité consiste à passer par des plateformes comme Fireworks.ai qui offre un bonus de 1 $ à l'inscription, suffisant pour traiter plus d'un million de tokens avec R1.[9]

Module	**Plateforme Recommandée**	**Modèle**	**Avantage Stratégique**
Chat Temps Réel	Groq	Llama 3.3 70B	Latence ultra-faible, idéal pour 3G/4G [1]
Raisonnement	DeepSeek	R1	Performance o1-level, coût minime [1]
Analyse Longue	Google AI Studio	Gemini 2.5 Flash	Contexte de 1M à 2M de tokens [1]
Agentic Coding	Zhipu AI	GLM-5	Optimisé pour l'exécution de tâches complexes [16]

Google AI Studio complète cet arsenal en tant que "workhorse" pour les volumes élevés. Avec une capacité de pomper jusqu'à un million de tokens par minute et une fenêtre de contexte allant jusqu'à 2 millions de tokens, Gemini 2.5 Flash permet à JadaRiseLabs d'offrir des fonctions d'analyse de documents massifs ou de bases de code entières sans frais d'API.[1]
L'intégration de ces quatre fournisseurs (Groq, DeepSeek, Google, et Zhipu) forme une infrastructure résiliente où chaque modèle est sollicité selon ses forces spécifiques : la vitesse pour Groq, la logique pour DeepSeek, le volume pour Google et l'ingénierie agentique pour Zhipu.[1]

Vision par Ordinateur et Intelligence Documentaire : Au-delà de l'OCR Simple

Pour devenir un laboratoire complet, JadaRiseLabs doit exceller dans la compréhension du monde physique et des documents. L'année 2025 a marqué une révolution dans ce domaine avec le passage des pipelines OCR traditionnels vers des modèles de langage visuel (VLM) de

bout en bout.[19] Mistral OCR, lancé début 2025, a établi un nouveau standard en comprenant chaque élément d'un document — média, texte, tableaux, équations — avec une précision cognitive inédite.[20] Il est capable de traiter jusqu'à 2000 pages par minute sur un seul nœud, ce qui en fait l'outil le plus rapide de sa catégorie pour les environnements à haut débit.[20] L'écosystème open-source a rattrapé les solutions propriétaires. Le modèle Chandra, basé sur l'architecture Qwen3-VL-8B, surpasse les services commerciaux dans la reconnaissance de l'écriture manuscrite et des documents dégradés.[19] Pour les besoins spécifiques de JadaRiseLabs, comme la numérisation de formulaires administratifs ou médicaux, Chandra offre une awareness spatiale supérieure, identifiant précisément les relations entre les étiquettes et les valeurs dans des mises en page complexes.[19]

Outil OCR / VLM	Architecture	Point Fort	Langues
Mistral OCR	Propriétaire	Vitesse et structure Markdown [20]	Multilingue natif
Chandra	Qwen3-VL-8B	Manuscrits et formulaires complexes [19]	40+ langues
InternVL 2.0	OpenGVLab	Haute résolution (4K), tuilage d'images [21]	Support global
dots.ocr	Qwen2.5-VL	Tableaux et formules mathématiques [19]	100+ langues
Nanonets OCR 2	Qwen2.5-VL	Marquage sémantique et tags HTML [19]	Anglais, Chinois, Français

Une technique "cachée" pour offrir la meilleure qualité OCR consiste à utiliser des modèles comme OlmOCR-2, entraînés spécifiquement sur des tests unitaires pour garantir la fidélité de l'extraction.[19] JadaRiseLabs peut également exploiter la puissance gratuite de Google Cloud Vision, qui offre les 1000 premières unités gratuitement chaque mois, pour les tâches de détection de visages, de logos et de monuments.[15] L'ensemble de ces outils permet de transformer des scans bruts en "or structuré" (Markdown, JSON ou LaTeX), une fonctionnalité à forte valeur ajoutée pour les utilisateurs professionnels et académiques.[19]

Synthèse Multimodale : La Puissance Créative de l'Image et de la Vidéo

Le module de génération d'images est souvent la porte d'entrée principale pour le grand public. JadaRiseLabs doit s'appuyer sur une plateforme unique offrant la qualité maximale. FLUX.1 de Black Forest Labs, accessible via l'API d'inférence de Hugging Face, est actuellement considéré comme le sommet de la qualité visuelle open-weight, surpassant Midjourney dans la gestion des détails anatomiques et des textes intégrés.[3] Pour une alternative issue de l'écosystème chinois, CogView-4 de Zhipu AI propose une génération extrêmement précise, notamment pour les descriptions en langue chinoise, tout en restant très compétitif en termes de coûts

d'inférence.[24]
La révolution la plus spectaculaire concerne la vidéo. Le modèle Hailuo 2.3 de MiniMax a redéfini le rapport coût-performance mondial, permettant de générer des clips cinématographiques avec une stabilité visuelle et une expression dynamique exceptionnelles.[25] MiniMax propose un système de crédits gratuits quotidiens pour tester ses modèles, ce qui est idéal pour l'amorçage de JadaRiseLabs.[25] Pour une qualité Full HD, le modèle Hailuo 02 Pro supporte une résolution 1080P avec une simulation physique réaliste.[27]

Modèle Multimodal	Type	Plateforme	Avantage
FLUX.1	Image	Hugging Face	Qualité photoréaliste, open-weight [3]
CogView-4	Image	BigModel.cn	Précision sémantique élevée [24]
Hailuo 2.3	Vidéo	MiniMax	Rapport coût-performance record [25]
Wan 2.1	Vidéo	Replicate	Cohérence temporelle sur 5-15s [3]
Bark	Audio	Hugging Face	Synthèse multilingue avec émotions [3]

L'audio ne doit pas être négligé. Au-delà de Bark, MiniMax Audio propose le modèle T2A-01-HD qui permet un clonage vocal à partir d'un échantillon de 10 secondes seulement, supportant 17 langues.[5] Cette capacité de "Voice Cloning" peut être intégrée pour créer des avatars vocaux personnalisés pour les créateurs de contenu africains, renforçant l'attractivité de la plateforme.[29]

Recherche Web en Temps Réel et Fondations RAG

Un laboratoire d'IA sans accès à l'information fraîche est une bibliothèque morte. JadaRiseLabs doit intégrer des capacités de recherche web pour "grounder" ses réponses dans la réalité actuelle. Tavily et Exa dominent ce segment avec des moteurs de recherche conçus nativement pour les agents IA.[30] Tavily se concentre sur la fourniture de sources vérifiées et de citations prêtes à l'emploi pour les pipelines RAG (Retrieval-Augmented Generation), minimisant ainsi les hallucinations.[31] Exa, de son côté, utilise la recherche sémantique profonde pour trouver des résultats basés sur le sens et l'intention plutôt que sur la simple occurrence de mots-clés, ce qui est particulièrement efficace pour les requêtes complexes.[30]

API de Recherche	Engine	Format de Sortie	Capacité RAG
Tavily	Propriétaire	JSON / Citations	Optimisé pour grounding [31]
Exa	Neural Network	Markdown / Résumés	Recherche sémantique

			pure [30]
Firecrawl	Serper-powered	Markdown complet	Scraping et recherche combinés [31]
Serper	Google SERP	Données structurées	Accès Google low-cost [30]
Brave Search	Independent Index	JSON / Goggles	Respect de la vie privée [30]

La disparition des APIs de recherche Bing en août 2025 a déplacé le marché vers ces solutions spécialisées.[31] Pour JadaRiseLabs, l'utilisation de l'endpoint /agent de Firecrawl représente une arme secrète : il permet de déléguer des tâches de recherche autonomes qui gèrent la navigation multi-étapes sur le web pour extraire des données propres, prêtes à être injectées dans un modèle de langage.[31]

Frameworks d'Orchestration Agentique et Automatisation

La valeur ajoutée de JadaRiseLabs ne réside pas seulement dans les modèles individuels, mais dans leur capacité à travailler ensemble. Les frameworks comme LangGraph et CrewAI permettent de concevoir des systèmes multi-agents où chaque agent possède un rôle et des outils spécifiques.[37] LangGraph, en particulier, permet de structurer les interactions sous forme de graphes d'états, offrant une traçabilité et une capacité de récupération d'erreurs indispensables pour des flux de travail robustes.[37]

Pour les développeurs, le passage à l'ingénierie agentique est facilité par des plateformes comme Zhipu AI qui propose des plans spécifiquement conçus pour les agents de codage, offrant 600 prompts par cycle de 5 heures sur le modèle GLM-4.5.[41] L'adoption du Model Context Protocol (MCP) devient le standard pour connecter les modèles à des sources de données externes et des outils, permettant à un agent de lire des fichiers Google Drive, de cartographier via Google Maps ou de requêter une base PostgreSQL de manière unifiée.[42]

Framework d'Agents	**Type**	**Force Majeure**	**Courbe d'Apprentissage**
LangGraph	Graphe d'états	Contrôle fin, flux cycliques [37]	Modérée à élevée
CrewAI	Role-based	Collaboration mimétique humaine [37]	Faible à modérée
AutoGen	Event-driven	Systèmes multi-agents complexes [37]	Élevée
OpenAI Agents SDK	Lightweight	Intégration stack OpenAI [38]	Faible
LlamaIndex Agents	RAG-focused	Planification de	Modérée

		recherche [37]	

Ces frameworks permettent à JadaRiseLabs de simuler des processus d'entreprise entiers, du support client automatisé (via Eesel AI qui s'entraîne sur la documentation existante en quelques minutes) à la création de rapports financiers complexes.[44]

Traduction Avancée et Adaptation Culturelle

La traduction est un module critique pour l'expansion de JadaRiseLabs, surtout pour adresser les barrières linguistiques en Afrique. Alors que DeepL reste supérieur pour la fluidité naturelle dans les langues européennes, Lara Translate émerge comme le choix stratégique pour les contextes professionnels et techniques.[47] Utilisant des modèles de langage de traduction (T-LMs) entraînés sur des corpus parallèles de haute qualité, Lara Translate maintient le ton et le registre appropriés pour les documents officiels.[48]
Pour une couverture massive, Google Cloud Translation supporte plus de 249 langues et dialectes, incluant des langues à faibles ressources comme le Swahili ou le Haoussa, ce qui est vital pour l'ancrage culturel de JadaRiseLabs.[50] Le module "Algebras AI" prétend même supporter plus de 322 langues et 1000 dialectes, offrant des capacités de localisation complètes.[53]

Solution de Traduction	**Type**	**Spécialité**	**Langues**
Lara Translate	T-LM Spécialisé	Précision business et MCP [48]	Corpus pro
DeepL	Neural MT	Nuance et idiomes [55]	33
Google Translate	NMT / LLM	Couverture globale et offline [50]	249+
Algebras AI	Full-stack	Localisation et dialectes [53]	322+
Bluente	Document AI	Préservation de la mise en page [57]	Secteurs régulés

L'utilisation créative des LLM (GPT-4o, Claude 4) pour la traduction permet d'aller au-delà du mot-à-mot : on peut demander à l'IA de réécrire un e-mail marketing pour qu'il paraisse plus "empathique" ou "diplomatique" dans une culture donnée, une capacité que les outils de traduction pure ne possèdent pas encore.[44]

Infrastructure Résiliente et Tactiques de Contournement (Dark AI)

La contrainte budgétaire impose une approche de "guérilla technique". Pour accéder à la puissance de modèles premium comme GPT-4o ou Claude 3.5 Sonnet sans frais, des solutions de proxies inversés non officiels pullulent sur GitHub.[59] Bien que risqués car violant les

conditions de service des fournisseurs originaux, des projets comme "Copilot API Proxy" transforment l'accès GitHub Copilot en un service compatible OpenAI ou Anthropic, permettant d'utiliser ces modèles au sein de n'importe quel outil tiers.[59]
Pour unifier et sécuriser ces accès, LiteLLM est l'outil indispensable. Il permet de gérer la rotation des clés d'API, le failover automatique vers un modèle de secours en cas d'erreur 429 (Rate Limit), et d'exposer un point d'entrée unique pour tous les modules de JadaRiseLabs.[61]
Une autre ressource majeure est Oracle Cloud Free Tier, qui offre gratuitement des instances Arm Ampere A1 (4 OCPU, 24 Go de RAM) capables d'héberger localement des modèles comme Whisper pour la transcription ou des serveurs d'inférence via Ollama.[64]

Ressource Infrastructure	Type	Capacité / Limite	Usage Recommandé
Oracle Cloud	IaaS	4 OCPU, 24 Go RAM [64]	Hébergement modèles locaux (Whisper)
Supabase	BaaS	10 Go Storage, Postgres RLS [3]	Backend et sécurité des données
Vercel	Hosting	Tier gratuit Next.js [3]	Frontend et API Routes
LiteLLM	Proxy	Open Source [61]	Orchestration et rotation de clés
NVIDIA NIM	Inference	40 req/min free [67]	Accès modèles SOTA optimisés

Les startups peuvent également bénéficier de programmes de subventions massifs. Yandex Cloud Boost AI offre jusqu'à 12 000 $ de crédits cloud pour l'implémentation de modèles génératifs comme YandexGPT et YandexART, avec une approbation en seulement sept jours pour les projets au stade MVP.[68] Ces crédits couvrent non seulement l'inférence IA mais aussi le stockage et les instances de calcul, offrant une piste d'envol financière inespérée.[68]

Localisation et Stratégie de Marché en Afrique de l'Ouest

L'ancrage culturel est le véritable avantage concurrentiel de JadaRiseLabs. Le nom même, combinant sagesse (Jada en Haoussa) et élévation (Rise), définit une mission de démocratisation.[3] L'intégration native du Mobile Money (Orange Money, Wave, MTN, Moov) via l'API CinetPay est le levier de conversion principal, permettant aux utilisateurs sans carte bancaire de passer aux plans payants Starter (500 F CFA) ou Pro (1500 F CFA).[3]
L'optimisation technique pour les connexions 3G/4G est un impératif de survie. Chaque milliseconde de latence économisée via des modèles servis par Groq ou l'utilisation de formats d'image WebP est une victoire pour l'adoption.[3] L'architecture doit être pensée "Offline-First" avec l'usage de Service Workers (PWA) et de mise en cache agressive des résultats via Redis (Upstash) pour éviter les appels API redondants et coûteux.[3]

Plan JadaRiseLabs	Prix (F CFA)	Crédits / Mois	Fonctionnalités
Gratuit	0	50	Basique, Watermark [3]
Starter	500	200	Image HD, Vidéo 5s [3]
Pro	1500	Illimité	Vidéo 15s, Pas de Watermark [3]

La sécurité des données, particulièrement lors de l'envoi de code ou de documents vers des serveurs étrangers (Chine/Russie), doit être gérée par des politiques de Row Level Security (RLS) strictes sur Supabase, garantissant que les créations d'un utilisateur restent strictement privées.[3] L'utilisation de filtres NSFW via l'API Hugging Face assure la conformité éthique nécessaire pour attirer des partenariats institutionnels.[3]

Conclusion et Recommandations Stratégiques

La construction du laboratoire JadaRiseLabs en 2025 repose sur une agilité technique extrême plutôt que sur une puissance financière. L'accès à la "Meilleure Qualité Possible" gratuitement est une réalité tangible, à condition de savoir où puiser les ressources. La stratégie recommandée se décompose en trois axes : l'orchestration multimodale, la résilience par les proxies et la localisation culturelle.

Premièrement, l'assemblage des "Meilleurs de leur catégorie" : utiliser DeepSeek-R1 pour la logique pure, Groq pour la réactivité du chat, FLUX.1 pour l'image, Hailuo 2.3 pour la vidéo, et Mistral OCR pour les documents. Cette combinaison offre un laboratoire dont les capacités dépassent largement les offres intégrées de géants comme Microsoft ou Google, souvent limitées par des contraintes de sécurité ou de coûts internes.[1]

Deuxièmement, la sécurisation des accès par la "Shadow AI" et les subventions cloud : exploiter les instances Oracle Cloud Always Free pour l'hébergement local et solliciter activement les crédits Yandex Cloud Boost ($12k) pour financer la phase de croissance initiale. Utiliser des outils de proxy comme LiteLLM pour masquer la complexité des backends et garantir une disponibilité de service à 99% même avec des clés gratuites.[61]

Enfin, transformer la technologie en produit par l'ancrage ouest-africain : en résolvant les problèmes de paiement locaux et en optimisant l'interface pour les contraintes réseau de la région, JadaRiseLabs crée une valeur que les acteurs globaux ne peuvent pas répliquer. La qualité des modules n'est pas une fin en soi, mais un moyen de gagner la confiance des utilisateurs et de construire une souveraineté numérique pour le continent.

Le futur de l'IA appartient à ceux qui sauront tisser ces fils technologiques mondiaux dans le tissu des réalités locales. JadaRiseLabs, en tant que laboratoire universel, a toutes les cartes en main pour mener cette transition, passant d'un projet à budget nul à un leader de l'innovation technologique en Afrique.

Sources des citations

1. Best Free AI APIs for 2025: Build with LLMs Without Spending a Penny - MadAppGang, consulté le mars 14, 2026, https://madappgang.com/blog/best-free-ai-apis-for-2025-build-with-llms-witho

ut/
2. China's AI Models Surge Ahead: A Global Developer's Choice - Oreate AI Blog, consulté le mars 14, 2026, http://oreateai.com/blog/chinas-ai-models-surge-ahead-a-global-developers-choice/bdce465c47fbecc4c7777a87ce3b46a4
3. JadaRiseLabs_CahierDesCharges_DetailleV2.docx-1.pdf
4. DeepSeek (chatbot) - Wikipedia, consulté le mars 14, 2026, https://en.wikipedia.org/wiki/DeepSeek_(chatbot)
5. Beyond DeepSeek: An Overview of Chinese AI Tigers and Their Cutting-Edge Innovations - TOPBOTS, consulté le mars 14, 2026, https://www.topbots.com/chinese-ai-tigers-overview/
6. China's AI Models Surge Ahead: A Global Developer's Choice ..., consulté le mars 14, 2026, https://oreateai.com/blog/chinas-ai-models-surge-ahead-a-global-developers-choice/bdce465c47fbecc4c7777a87ce3b46a4
7. Top 6 Chinese AI Models Like DeepSeek (LLMs) You Should Know in 2026 - Index.dev, consulté le mars 14, 2026, https://www.index.dev/blog/chinese-ai-models-deepseek
8. Best Generative AI APIs in 2025 - C# Corner, consulté le mars 14, 2026, https://www.c-sharpcorner.com/article/best-generative-ai-apis-in-2025/
9. uplabzh/best-ai-api-tools: Top 12 Best AI API Platforms in 2025 (Latest Updated) - GitHub, consulté le mars 14, 2026, https://github.com/uplabzh/best-ai-api-tools
10. BREAKING: Free AI API Keys 2025: 3 Secret Platforms Replacing Paid Services - Dev.to, consulté le mars 14, 2026, https://dev.to/itshayder/breaking-free-ai-api-keys-2025-3-secret-platforms-replacing-paid-services-2708
11. DeepSeek and Making the Right LLM API Call in 2025 | by David Haberlah | Medium, consulté le mars 14, 2026, https://medium.com/@haberlah/making-the-right-llm-api-call-in-feb-25-a2468aa6bb9a
12. Run DeepSeek API - How to Use the DeepSeek API - Clarifai, consulté le mars 14, 2026, https://www.clarifai.com/blog/how-to-use-the-deepseek-api
13. How to Use DeepSeek API for Free: Hands-On Integration Guide | Aionlinecourse, consulté le mars 14, 2026, https://www.aionlinecourse.com/blog/how-to-use-deepseek-api-for-free-hands-on-integration-guide
14. DeepSeek Free Plans, Trials, and Subscriptions: Token Grants, Usage Caps, and API Pricing Strategies for Late 2025/2026 - Data Studios, consulté le mars 14, 2026, https://www.datastudios.org/post/deepseek-free-plans-trials-and-subscriptions-token-grants-usage-caps-and-api-pricing-strategies
15. 10+ Free AI tools for 2026 | Google Cloud, consulté le mars 14, 2026, https://cloud.google.com/use-cases/free-ai-tools
16. Zhipu AI releases GLM-4.7: Beating GPT-5.2 and Claude 4.5 Sonnet in Coding & Reasoning Benchmarks : r/singularity - Reddit, consulté le mars 14, 2026,

https://www.reddit.com/r/singularity/comments/1pt38jt/zhipu_ai_releases_glm47_beating_gpt52_and_claude/
17. GLM-5: From Vibe Coding to Agentic Engineering - Z.ai, consulté le mars 14, 2026, https://z.ai/blog/glm-5
18. AI coding tools that give free Claude Opus/Sonnet, GPT-5, Gemini Pro, and other pro-grade models - GitHub, consulté le mars 14, 2026, https://github.com/inmve/free-ai-coding
19. 7 Best Open-Source OCR Models 2025: Benchmarks & Cost Comparison | E2E Networks, consulté le mars 14, 2026, https://www.e2enetworks.com/blog/complete-guide-open-source-ocr-models-2025
20. Mistral OCR, consulté le mars 14, 2026, https://mistral.ai/news/mistral-ocr
21. 10 Awesome OCR Models for 2025 - KDnuggets, consulté le mars 14, 2026, https://www.kdnuggets.com/10-awesome-ocr-models-for-2025
22. Beyond Text Extraction: The 2025 Open OCR Revolution Powered by Vision-Language Models | by TechEon, consulté le mars 14, 2026, https://atul4u.medium.com/beyond-text-extraction-the-2025-open-ocr-revolution-powered-by-vision-language-models-89ad33d36bbf
23. 12 Best AI APIs [2025] - Tavus, consulté le mars 14, 2026, https://www.tavus.io/post/ai-apis
24. Product Pricing - ZHIPU AI OPEN PLATFORM, consulté le mars 14, 2026, https://open.bigmodel.cn/pricing
25. MiniMax Hailuo 2.3: A New Level of Complex Video Performance & Media Agent, consulté le mars 14, 2026, https://www.minimax.io/news/minimax-hailuo-23
26. Hailuo AI Video Subscription Service Terms, consulté le mars 14, 2026, https://hailuoai.video/doc/payment-policy.html
27. Free Hailuo 02 API – Try Minimax Hailuo AI API Online - Kie.ai, consulté le mars 14, 2026, https://kie.ai/hailuo-api
28. 7 free AI APIs most developers miss (2026 guide), consulté le mars 14, 2026, https://www.eesel.ai/blog/free-ai-api
29. MiniMax AI, consulté le mars 14, 2026, https://www.minimax.io/
30. 7 Free Web Search APIs for AI Agents - KDnuggets, consulté le mars 14, 2026, https://www.kdnuggets.com/7-free-web-search-apis-for-ai-agents
31. Best Web Search APIs for AI Applications in 2026 - Firecrawl, consulté le mars 14, 2026, https://www.firecrawl.dev/blog/best-web-search-apis
32. Exa | Web Search API, AI Search Engine, & Website Crawler, consulté le mars 14, 2026, https://exa.ai/
33. Best Web Search APIs for LLM Training Data Aggregation - The Emory Wheel, consulté le mars 14, 2026, https://emorywheel.com/article/best-web-search-apis-for-llm-training-data-aggregation-20251230
34. 9 top AI Search Engine tools in 2026 - Composio Dev, consulté le mars 14, 2026, https://composio.dev/blog/9-top-ai-search-engine-tools
35. Best SERP APIs & Web Search APIs in 2025 - Linkup, consulté le mars 14, 2026, https://www.linkup.so/blog/best-serp-apis-web-search

36. 7 Best Web Search APIs for Real-Time Data & AI Apps - Crustdata, consulté le mars 14, 2026, https://crustdata.com/blog/best-websearch-apis
37. Top AI Agent Frameworks in 2025 - Codecademy, consulté le mars 14, 2026, https://www.codecademy.com/article/top-ai-agent-frameworks-in-2025
38. The Best Open Source Frameworks For Building AI Agents in 2026 - Firecrawl, consulté le mars 14, 2026, https://www.firecrawl.dev/blog/best-open-source-agent-frameworks
39. Best AI Agent Frameworks 2025: LangGraph, CrewAI, OpenAI, LlamaIndex, AutoGen, consulté le mars 14, 2026, https://www.getmaxim.ai/articles/top-5-ai-agent-frameworks-in-2025-a-practical-guide-for-ai-builders/
40. Best 10 AI Agent Frameworks for 2025 - Deepchecks, consulté le mars 14, 2026, https://deepchecks.com/best-ai-agent-frameworks/
41. Z AI (Zhipu AI) - Cline Documentation, consulté le mars 14, 2026, https://docs.cline.bot/provider-config/zai
42. Tools and APIs for building AI Agents in 2025 : r/AI_Agents - Reddit, consulté le mars 14, 2026, https://www.reddit.com/r/AI_Agents/comments/1jikig2/tools_and_apis_for_building_ai_agents_in_2025/
43. modelcontextprotocol/servers: Model Context Protocol Servers - GitHub, consulté le mars 14, 2026, https://github.com/modelcontextprotocol/servers
44. I tested 7 DeepL alternatives to find the best for multilingual support in 2025 - eesel AI, consulté le mars 14, 2026, https://www.eesel.ai/blog/deepl-alternatives
45. 7 APIs IA gratuites que la plupart des développeurs ignorent (2026) - eesel AI, consulté le mars 14, 2026, https://www.eesel.ai/fr/blog/free-ai-api
46. I tried a dozen models to find the 7 best Qwen alternatives in 2025, consulté le mars 14, 2026, https://www.eesel.ai/blog/qwen-alternatives
47. Ultimate Guide - The Best AI Translation API Alternative to DeepL of 2026 - X-doc, consulté le mars 14, 2026, https://x-doc.ai/usecases/en/the-best-ai-translation-api-alternative-to-deepl
48. DeepL alternatives: 5+1 best AI translators in 2025, consulté le mars 14, 2026, https://blog.laratranslate.com/best-deepl-alternatives-translators/
49. 6 Top Translation APIs for Developers, consulté le mars 14, 2026, https://blog.laratranslate.com/top-translation-apis-for-developers/
50. DeepL vs. Google Translate vs. Taia: Best AI file translators in 2025 | Taia Blog, consulté le mars 14, 2026, https://taia.io/resources/blog/deepl-vs-google-translate-vs-taia-best-ai-file-translators-compared/
51. Best DeepL Alternative For Real Time Translation - BeLikeNative, consulté le mars 14, 2026, https://belikenative.com/best-deepl-alternative-real-time-translation/
52. The best translation tools for 2025 - Smartling, consulté le mars 14, 2026, https://www.smartling.com/blog/translation-tools
53. Best AI translation software for 2026: 11 leading solutions compared | Gridly, consulté le mars 14, 2026, https://www.gridly.com/blog/best-ai-translation-software-explore-these-9-soluti

ons/
54. The Best Translation Software in 2025: Compare 33 Tools by Features, Pricing, and Use Case | Taia Blog, consulté le mars 14, 2026, https://taia.io/resources/blog/best-translation-software/
55. Top Alternatives to Google Translate: Best Pick of 2025 - Kroolo, consulté le mars 14, 2026, https://kroolo.com/blog/google-translate-alternative
56. AI Text Translation Tool: 31 Best Options 2026, consulté le mars 14, 2026, https://qcall.ai/ai-text-translation-tool
57. Best AI Translation Tools in 2025 | Bluente Blog, consulté le mars 14, 2026, https://www.bluente.com/blog/best-ai-translation-tools-in-2025
58. Les 38 meilleurs outils d'IA gratuits en 2026 : Un guide complet - DataCamp, consulté le mars 14, 2026, https://www.datacamp.com/fr/blog/free-ai-tools
59. IT-BAER/copilot-api-proxy - GitHub, consulté le mars 14, 2026, https://github.com/IT-BAER/copilot-api-proxy
60. ai-proxy · GitHub Topics, consulté le mars 14, 2026, https://github.com/topics/ai-proxy
61. A cost-optimized proxy for routing between GPT-4o, Claude 3.5 Sonnet, and Gemini 1.5 Pro using LiteLLM. - GitHub Gist, consulté le mars 14, 2026, https://gist.github.com/ruvnet/e7b9bfa62c62a95aabd15c22710fd624
62. Mirrowel/LLM-API-Key-Proxy: Universal LLM Gateway: One API, every LLM. OpenAI/Anthropic-compatible endpoints with multi-provider translation and intelligent load-balancing. - GitHub, consulté le mars 14, 2026, https://github.com/Mirrowel/LLM-API-Key-Proxy
63. Nikunj2003/codenex-ai-api-proxy - GitHub, consulté le mars 14, 2026, https://github.com/Nikunj2003/codenex-ai-api-proxy
64. FAQ on Oracle's Cloud Free Tier, consulté le mars 14, 2026, https://www.oracle.com/cloud/free/faq/
65. Always Free Resources - Oracle, consulté le mars 14, 2026, https://docs.oracle.com/iaas/Content/FreeTier/freetier_topic-Always_Free_Resources.htm
66. free-ai-api · GitHub Topics, consulté le mars 14, 2026, https://github.com/topics/free-ai-api?o=asc&s=updated
67. Use claude-code for free in the terminal, VSCode extension or via discord like openclaw - GitHub, consulté le mars 14, 2026, https://github.com/Rishurajgautam24/free-claude-code
68. YandexGPT 5 — Generative AI for Business - Yandex Cloud, consulté le mars 14, 2026, https://yandex.cloud/en/services/yandexgpt
69. Yandex Cloud Boost - loyalty program for software and digital product developers, consulté le mars 14, 2026, https://yandex.cloud/en/cloud-boost
70. Yandex Cloud Boost AI, consulté le mars 14, 2026, https://yandex.cloud/en/cloud-boost-ai
71. Free tier | Yandex Cloud - Documentation, consulté le mars 14, 2026, https://yandex.cloud/en/docs/billing/concepts/serverless-free-tier
72. A Year After DeepSeek Launch - AI Governance & Security Platform | Harmonic Security, consulté le mars 14, 2026,

https://www.harmonic.security/resources/a-year-after-deepseek-launch-1-in-12-employees-used-china-based-ai-tools-in-the-last-month-but-kimi-moonshot-way-ahead-of-all-other-chinese-ai-tools-hiding-in-your-enterprise